

Lancet v3: Policy-Sensitive Projected Bellman Residual Learning

2026-09-05

Lancet v3: Policy-Sensitive Projected Bellman Residual Learning

0. 核心结论

Lancet 的目标不是重新学习一个完整的新 Critic，也不是显式恢复真实的 action-dependent error，而是在正常 Offline-to-Online (O2O) Critic 更新之外增加一条**小型、快速、受限的 residual correction branch**。

核心形式为：

$$Q^{\text{use}}(s, a) = Q(s, a) + \Delta(s, a)$$

其中：

- Q ：原 O2O 算法中的 Base Critic；
- Δ ：Lancet Residual 网络产生的 correction；
- Q^{use} ：在 handoff 初期给 Actor 使用的修复后 Critic。

Lancet 的关键约束不是让 Δ 任意拟合 TD residual，而是让它尽量只表达**同一状态下随 action 变化的 correction**：

$$\Delta(s, a) = R(s, a) - \mathbb{E}_{a' \sim q(\cdot|s)} R(s, a')$$

其中 R 是小型 Residual 网络， $q(a|s)$ 是围绕当前 policy 的局部 action 分布。

因此，Lancet 的一句话可以概括为：

Base Critic 继续学习完整 Bellman correction；Residual branch 额外加速其中 policy-sensitive 的 action-relative correction。

1. 问题设定

Offline 阶段训练得到：

$$\pi_0, \quad Q_0.$$

进入 Online 阶段后，继续通过正常 RL 算法更新 Critic。对一个 transition：

$$(s, a, r, s')$$

原算法计算 TD target：

$$y.$$

Base Critic 当前的 TD residual 为：

$$\delta(s, a) = y - Q(s, a).$$

普通 O2O 方法直接最小化：

$$L_Q = (Q(s, a) - y)^2.$$

也就是说，Base Critic 自己通过参数更新逐步吸收 δ 。

Lancet 不改变这一条主路径，而是在旁边增加：

$$Q^{\text{use}} = Q + \Delta.$$

Residual 网络尝试更快学习当前 Base Critic 尚未吸收的 correction。

2. 为什么使用 Residual 网络是合理的

把修复后的 Critic 写成：

$$Q^{\text{use}} = Q + \Delta.$$

若希望它拟合 TD target，则有：

$$(Q + \Delta - y)^2.$$

整理：

$$Q + \Delta - y = \Delta - (y - Q).$$

因此：

$$\boxed{(Q + \Delta - y)^2 = (\Delta - \delta)^2}$$

其中：

$$\delta = y - Q.$$

这说明：

让一个 Residual 网络去拟合 TD residual，与让 “Base Critic + Residual” 整体拟合 Bellman target，在平方损失下是同一个目标的重新参数化。

因此 Residual fitting 本身并不是额外假设出来的 heuristic，而是 Bellman regression 的一种 additive parameterization。

已有强化学习工作中，Boosted Fitted Q-Iteration (B-FQI) 也采用类似思想：保留当前 Q ，再学习 Bellman residual $TQ - Q$ 的近似，并将其加回当前价值函数。

Lancet 的区别在于：

1. 目标场景是 Offline-to-Online handoff;
2. Base Critic 不被替换;
3. Residual branch 被限制为 action-relative correction;
4. Residual 主要作为 handoff 初期的 fast adaptation channel。

3. 为什么不让 Residual 任意拟合 TD residual

考虑 Critic error：

$$e(s, a) = b(s) + \xi(s, a),$$

其中：

- $b(s)$ ：同一状态下所有 action 共享的误差；
- $\xi(s, a)$ ：随 action 变化的误差。

对一类满足

$$\mathcal{U}(Q + c(s)) = \mathcal{U}(Q)$$

的 Actor update，state-common shift $c(s)$ 是 policy-insensitive direction。

因此，如果 Residual 完全自由：

$$\Delta(s, a) = R(s, a),$$

它可能花大量容量学习：

$$\Delta(s, a) \approx c(s),$$

但这种 correction 对当前 Actor 决策并不重要。

Lancet 因此从结构上限制 Residual：

$$\Delta(s, a) = R(s, a) - \mathbb{E}_{a' \sim q(\cdot|s)} R(s, a')$$

于是自动满足：

$$\mathbb{E}_{a \sim q} \Delta(s, a) = 0.$$

这意味着 Residual 无法表达纯 state-common correction。

4. Local action distribution

Lancet 不需要关心整个 action space，只希望修复当前 Actor 在 handoff 阶段真正可能比较或访问的 action。

定义局部动作分布：

$$a \sim q(a|s).$$

一个简单实现是：

$$a_k = \pi(s) + \sigma \epsilon_k, \quad \epsilon_k \sim \mathcal{N}(0, I).$$

实际每个 state 可以构造：

$$A(s) = \{a_1, \dots, a_K\}.$$

推荐第一版：

- $K = 8$;
- 包含当前 Actor action;
- 包含 replay 中真实 action;
- 其余动作由 Actor action 附近的小扰动生成;
- 连续控制环境中对 action 做合法范围 clipping。

这样 Lancet 修的是：

$$\text{policy-local action geometry}$$

而不是任意 OOD action。

5. Residual 的具体计算

对 Critic Q_i 配一个小型 Residual 网络:

$$R_i(s, a).$$

对于同一状态的 K 个 local actions:

$$a_1, \dots, a_K,$$

先计算:

$$r_{ik} = R_i(s, a_k).$$

求局部均值:

$$\bar{r}_i(s) = \frac{1}{K} \sum_{k=1}^K r_{ik}.$$

最终 Residual correction:

$$\Delta_i(s, a_k) = r_{ik} - \bar{r}_i(s).$$

因此:

$$\frac{1}{K} \sum_{k=1}^K \Delta_i(s, a_k) = 0.$$

实际 Actor 使用:

$$Q_i^{\text{use}}(s, a) = Q_i(s, a) + \Delta_i(s, a).$$

6. Base Critic 的更新

Base Critic 完全保留原 O2O 算法。

例如 twin critics:

$$Q_1, Q_2.$$

Base loss:

$$L_{\text{base}} = (Q_1 - y)^2 + (Q_2 - y)^2.$$

这一部分只更新 Base Critic 参数。

Lancet 不改变：

- TD target 的定义；
- replay buffer；
- target network；
- Base Critic optimizer；
- 原算法的主要 Bellman learning 路径。

7. Residual branch 的监督信号

对 replay 中真实执行的 action a ，计算：

$$\delta_i = \text{sg}(y - Q_i(s, a)).$$

其中 sg 表示 stop-gradient。

Residual 网络在真实 replay action 上接受：

$$L_{\text{fit}} = (\Delta_i(s, a) - \delta_i)^2.$$

直观上：

Base Critic 当前还差多少，Residual 就尝试快速补多少。

需要强调：在 model-free replay 中，我们通常只有真实执行 action 的 TD residual，并不知道同一状态下所有 counterfactual action 的真实 TD residual。

因此实际的 L_{fit} 是**单点 TD supervision**。

Residual 在 local action neighborhood 上的结构，主要由其函数参数化与 zero-mean constraint 共同决定。

8. Action-dependent uncertainty proxy $U(s)$

Lancet 需要判断：

哪些 state 的 action-relative Critic structure 更值得快速修复？

对于 twin critics：

$$Q_1, \quad Q_2$$

在同一 state 下计算：

$$d_k = Q_1(s, a_k) - Q_2(s, a_k).$$

定义：

$$U(s) = \text{Var}_k[d_k].$$

等价写成：

$$U(s) = \frac{1}{K} \sum_k (d_k - \bar{d})^2.$$

其中：

$$\bar{d} = \frac{1}{K} \sum_k d_k.$$

9. 为什么 $U(s)$ 能消除 state-common disagreement

假设：

$$Q_1 = Q^* + b_1(s) + \xi_1(s, a),$$

$$Q_2 = Q^* + b_2(s) + \xi_2(s, a).$$

两者相减：

$$Q_1 - Q_2 = [b_1(s) - b_2(s)] + [\xi_1(s, a) - \xi_2(s, a)].$$

对于固定 state：

$$b_1(s) - b_2(s)$$

是关于 action 的常数。

因此：

$$\text{Var}_a(Q_1 - Q_2) = \text{Var}_a(\xi_1 - \xi_2).$$

所以：

$U(s)$ 严格忽略 state-common disagreement, 只保留 action-dependent disagreement.

这一点不需要额外近似。

10. 为什么 $U(s)$ 只能是风险 proxy

需要明确：

$$U(s) \neq \text{true action-dependent error.}$$

例如：

$$Q^* = [1, 2, 3],$$

但：

$$Q_1 = Q_2 = [3, 2, 1].$$

此时：

$$U = 0,$$

但两个 Critic 都错了。

因此 Lancet 不允许 U 决定 correction 的方向。

真正的修复方向始终来自：

$$\delta = y - Q.$$

U 只负责：

prioritization / weighting

即判断哪些 state 应该让 Residual 学得更积极。

11. Uncertainty weighting

可以定义：

$$w(s) = 1 + \beta \frac{U(s)}{\text{EMA}(U) + \epsilon}.$$

然后做 clipping：

$$w(s) \in [1, w_{\max}].$$

Residual fitting loss 变成：

$$L_{\text{fit}} = w(s)(\Delta - \delta)^2.$$

含义：

- U 小：正常修；
- U 大：Residual 获得更大的 gradient；
- correction 的方向仍然由 TD residual 决定。

推荐第一版参数：

$$\beta \in [0.5, 2],$$

$$w_{\max} \in [2, 5].$$

12. Minimal-surgery 正则

为避免 Residual 过度修改 Critic，加入：

$$L_{\text{small}} = \frac{1}{K} \sum_k \Delta(s, a_k)^2.$$

最终 Residual objective：

$$L_R = w(s)(\Delta(s, a) - \delta)^2 + \mu \frac{1}{K} \sum_k \Delta(s, a_k)^2.$$

其中：

- 第一项：快速拟合 TD residual；

- 第二项：限制 correction 规模。

第一版方法不建议再加入强制 twin consistency loss。

13. 为什么暂时不使用额外的 relative-consistency loss

曾考虑加入：

$$\text{Var}_a(Q_1^{\text{use}} - Q_2^{\text{use}})$$

来直接压低 repaired twins 的 relative disagreement。

但存在一个问题：

$$\text{agreement} \neq \text{correctness}.$$

两个 Critic 可以一起错，而 ensemble diversity 本身在 uncertainty estimation 中有价值。

因此当前主方法中：

$U(s)$ 只用于 weighting，不直接被最小化。

relative-consistency loss 可以保留为实验 ablation，但不建议作为 Lancet v3 的主目标。

14. 完整训练流程

一次 online gradient step：

Step 1: 采样 replay batch

$$(s, a, r, s')$$

来自原 O2O replay buffer。

Step 2: 计算原算法 TD target

$$y = \text{BaseAlgorithmTarget}(r, s').$$

Step 3: 更新 Base Critic

$$L_{\text{base}} = (Q_1 - y)^2 + (Q_2 - y)^2.$$

正常执行 Base Critic optimizer。

Step 4: 生成 local actions

对每个 s :

$$a_1, \dots, a_K \sim q(a|s).$$

其中包含:

- Actor action;
- replay action;
- policy-nearby perturbations。

Step 5: 计算 $U(s)$

$$U(s) = \text{Var}_k[Q_1(s, a_k) - Q_2(s, a_k)].$$

Base Critic 对 U 的计算 stop-gradient。

Step 6: 计算 Residual

$$r_{ik} = R_i(s, a_k),$$

$$\bar{r}_i = \frac{1}{K} \sum_k r_{ik},$$

$$\Delta_i(s, a_k) = r_{ik} - \bar{r}_i.$$

Step 7: 计算 observed TD residual

对 replay action:

$$\delta_i = \text{sg}(y - Q_i(s, a)).$$

Step 8: 更新 Residual

$$L_R = w(U)(\Delta_i(s, a) - \delta_i)^2 + \mu \frac{1}{K} \sum_k \Delta_i(s, a_k)^2.$$

只更新 Residual 网络参数。

Step 9: Actor update

handoff early stage 中, Actor 使用:

$$Q_i^{\text{use}} = Q_i + \Delta_i.$$

推荐第一版: **Base Critic 的 TD target 暂时不使用 Residual correction.**

这样可以避免:

$$\Delta \rightarrow target \rightarrow \Delta$$

形成新的不稳定反馈环。

后续可把 “Residual 是否进入 target” 作为 ablation。

15. 推荐网络结构

第一版不需要复杂网络。

Residual network:

$$R_i(s, a)$$

可采用:

[state, action]

↓

Linear

↓

ReLU

↓

Linear

↓

ReLU

↓

Linear → scalar

推荐:

- 2 hidden layers;
- hidden size 64 或 128;
- 最后一层 zero initialization;
- Residual LR 为 Base Critic LR 的 2~5 倍;
- twin critics 对应两个 Residual heads。

更省参数的版本可以共享 feature encoder, 只独立最后的 Residual heads。

16. 为什么最后一层 zero initialization

若：

$$R_i(s, a) = 0,$$

则：

$$\Delta_i = 0.$$

因此训练开始时：

$$Q_i^{\text{use}} = Q_i.$$

也就是说：

Lancet 初始化时严格退化为 Base O2O algorithm。

之后只有获得 online TD evidence 后才开始修复。

17. Handoff 时间设计

Lancet 的目标是 early-online acceleration，不是永久替代 Base Critic。

可以使用：

$$\lambda(t)$$

对 Residual 影响逐渐衰减。

例如 Actor-facing correction：

$$Q^{\text{use}} = Q + \lambda(t)\Delta.$$

简单形式：

$$\lambda(t) = \exp(-t/\tau).$$

或者：

$$\lambda(t) = \begin{cases} 1, & t < T \\ 0, & t \geq T. \end{cases}$$

推荐第一版先使用固定 handoff window，例如前 50k online steps。

18. 理论一：Residual fitting 等价于 additive Bellman regression

Proposition 1

固定 Base Critic Q 与 Bellman target y , 优化:

$$\min_{\Delta} (Q + \Delta - y)^2$$

等价于:

$$\min_{\Delta} (\Delta - (y - Q))^2.$$

Proof

直接展开:

$$Q + \Delta - y = \Delta - (y - Q).$$

因此:

$$(Q + \Delta - y)^2 = (\Delta - (y - Q))^2.$$

证毕。

含义

Residual branch 并不是在拟合一个人为构造的新目标。

它拟合的恰好是:

Base Critic 尚未解释掉的 Bellman correction.

19. 理论二：Action centering 是正交投影

固定一个 state, 考虑动作分布 $q(a|s)$ 。

定义函数空间:

$$\mathcal{H} = \{f : \mathbb{E}_{a \sim q} f(a) = 0\}.$$

对于任意函数 $g(a)$, 定义:

$$Pg = g - \mathbb{E}_a g.$$

Proposition 2

Pg 是 g 在 zero-mean action-relative subspace $\mathcal{H}$ 上的正交投影。

Proof

首先：

$$\mathbb{E}_a[Pg] = \mathbb{E}_a g - \mathbb{E}_a g = 0.$$

因此：

$$Pg \in \mathcal{H}.$$

剩余部分：

$$g - Pg = \mathbb{E}_a g$$

是关于 action 的常数。

对任意：

$$h \in \mathcal{H},$$

有：

$$\langle g - Pg, h \rangle = \mathbb{E}_a[(\mathbb{E}_a g)h(a)]$$

$$= (\mathbb{E}_a g)(\mathbb{E}_a h) = 0.$$

因此：

$$g - Pg$$

与 $\mathcal{H}$ 正交。

所以 Pg 就是正交投影。

证毕。

20. 理论三：受限 Residual 会自动提取 action-dependent TD residual

假设理想情况下，对于同一个 state，我们知道所有 relevant actions 的 TD residual：

$$\delta(a).$$

分解：

$$\delta(a) = \bar{\delta} + \delta_A(a),$$

其中：

$$\bar{\delta} = \mathbb{E}_a \delta(a),$$

$$\mathbb{E}_a \delta_A(a) = 0.$$

考虑：

$$\min_{\Delta \in \mathcal{H}} \mathbb{E}_a [(\Delta(a) - \delta(a))^2].$$

Proposition 3

最优解为：

$$\Delta^*(a) = \delta(a) - \mathbb{E}_a \delta(a) = \delta_A(a).$$

Proof

由 Proposition 2，最优 zero-mean approximation 就是：

$$P\delta.$$

所以：

$$\Delta^* = P\delta = \delta - \mathbb{E}_a \delta.$$

证毕。

含义

如果 Residual 的函数空间只能表达 zero-mean action-relative correction, 那么即使训练目标是完整 TD residual:

$$\delta,$$

它理论上也只会吸收:

$\text{TD residual 的 action-dependent projection.}$

state-common component 则继续交给 Base Critic。

21. 理论四：加入 Minimal-surgery 后的最优解

考虑:

$$\min_{\Delta \in \mathcal{H}} \mathbb{E}[(\Delta - \delta)^2] + \mu \mathbb{E}[\Delta^2].$$

Proposition 4

最优解:

$$\Delta^* = \frac{1}{1 + \mu} P\delta.$$

即:

$$\Delta^* = \frac{1}{1 + \mu} (\delta - \mathbb{E}_a \delta).$$

Proof

因为 $\Delta \in \mathcal{H}$, 只需要考虑:

$$P\delta.$$

目标变成:

$$\|\Delta - P\delta\|^2 + \mu \|\Delta\|^2 + \text{constant}.$$

对 Δ 求导:

$$2(\Delta - P\delta) + 2\mu\Delta = 0.$$

于是：

$$(1 + \mu)\Delta = P\delta.$$

得到：

$$\Delta^* = \frac{1}{1 + \mu}P\delta.$$

证毕。

含义

μ 不只是普通 L2 regularization。

它决定：

Lancet 对 action-dependent Bellman residual 的 shrinkage 强度。

22. 理论五： $U(s)$ 消除 state-common disagreement

假设：

$$Q_1 = Q^* + b_1 + \xi_1,$$

$$Q_2 = Q^* + b_2 + \xi_2.$$

其中 b_i 与 action 无关。

定义：

$$U = \text{Var}_a(Q_1 - Q_2).$$

Proposition 5

有：

$$U = \text{Var}_a(\xi_1 - \xi_2).$$

Proof

$$Q_1 - Q_2 = (b_1 - b_2) + (\xi_1 - \xi_2).$$

而 variance 对常数平移不敏感：

$$\text{Var}(X + c) = \text{Var}(X).$$

所以：

$$U = \text{Var}_a(\xi_1 - \xi_2).$$

证毕。

含义

U 与 Lancet 的 motivation 严格对齐：

它不会因为两个 Critic 只是整体 value scale 不同而变大；只有 action-dependent disagreement 才会提高 U 。

23. $U(s)$ 什么时候近似真实 action-dependent error

进一步：

$$U = \mathbb{E}[\xi_1^2] + \mathbb{E}[\xi_2^2] - 2\mathbb{E}[\xi_1\xi_2].$$

若两个 Critic：

- 初始化不同；
- 训练噪声不同；
- action-dependent errors 不完全相关；

则 covariance 项较小：

$$\mathbb{E}[\xi_1\xi_2] \approx 0.$$

此时：

$$U \approx \mathbb{E}[\xi_1^2] + \mathbb{E}[\xi_2^2].$$

因此 U 可以作为 true action-dependent error energy 的 proxy。

但该近似不是普遍保证，所以论文中应将 U 称为：

policy-sensitive disagreement / uncertainty proxy

而不是 true error estimator。

24. 当前理论与实际实现之间的关键差距

Proposition 3 的理想结果：

$$\Delta^* = P\delta$$

隐含一个强条件：

对同一个 state，需要知道多个 action 的 TD residual。

但实际 model-free replay 通常只有：

$$(s, a, r, s').$$

因此只知道：

$$\delta(s, a)$$

而不知道附近：

$$a_1, \dots, a_K$$

各自真实的 TD residual。

所以：

Proposition 3 是 Oracle / idealized projection result。

实际 Lancet 依赖：

1. replay action 上真实 TD supervision;
2. Residual 网络在 state-action 空间中的函数泛化;
3. zero-mean action-relative architecture;
4. local action sampling;
5. $U(s)$ 对高风险 state 的 prioritization。

因此 practical Lancet 是否能逼近 oracle projection，需要实验验证，不能仅靠理论宣称。

25. Tabular 实验应如何验证这一理论

Tabular 环境中通常可以获得所有 action 的 Bellman residual。

因此可以直接构造：

$$\delta(s, a).$$

然后：

$$\Delta_{\text{oracle}} = \delta(s, a) - \mathbb{E}_a \delta(s, a).$$

比较：

Base

正常 TD learning。

Fast Residual

Residual 直接学习 TD correction，但不做 action projection。

Learned Lancet

只使用实际 transition supervision，并使用 zero-mean Residual。

Oracle Lancet

直接使用：

$$\Delta_{\text{oracle}}.$$

理想结果是在 early-stage repair speed / regret / ranking 指标上出现：

$\text{Base} < \text{Fast Residual} < \text{Learned Lancet} < \text{Oracle Lancet}.$
--

这可以把：

理论 projection

与：

实际 function approximation

连接起来。

26. Deep RL 实验重点

Lancet 的主 claim 不应是最终 asymptotic return 必然更高，而应是：

Critic 在 handoff 早期修复得更快。

推荐重点报告：

- Action-dependent error RMS;
 - State-common error RMS;
 - Action-dependent MSE fraction;
 - MC regret;
 - Top-1 action match;
 - within-state ranking correlation;
 - early-online return AUC;
 - steps-to-threshold;
 - 最终 return;
 - Residual norm;
 - $U(s)$ 与真实 action-dependent error 的相关性。
-

27. 最重要的消融实验

建议至少：

Method	Residual	Action centering	U weighting	Small penalty
Base	No	No	No	No
Raw Residual	Yes	No	No	Yes
Centered Residual	Yes	Yes	No	Yes
Lancet	Yes	Yes	Yes	Yes

这样可以分别回答：

1. Residual branch 本身是否有用？
 2. action-relative parameterization 是否比普通 residual 更有效？
 3. U -weighting 是否进一步提升 early repair？
 4. 最终 Lancet 的收益是不是来自 motivation 所强调的 policy-sensitive structure？
-

28. 实现伪代码

```
for gradient_step in range(num_steps):  
    # 1. Sample normal 020 replay batch  
    s, a, r, s_next = replay.sample()
```

```

# 2. Base algorithm TD target
with torch.no_grad():
    y = compute_base_td_target(r, s_next)

# 3. Base critic update
q1 = Q1(s, a)
q2 = Q2(s, a)

loss_base = mse(q1, y) + mse(q2, y)

critic_optimizer.zero_grad()
loss_base.backward()
critic_optimizer.step()

# 4. Build local action set
with torch.no_grad():
    a_pi = actor(s)
    actions = [
        a,
        a_pi,
        *sample_local_actions(a_pi, K - 2)
    ]

# 5. Compute policy-sensitive disagreement U
with torch.no_grad():
    q1_local = Q1(s, actions)
    q2_local = Q2(s, actions)

    diff = q1_local - q2_local
    U = variance_over_actions(diff)

    w = 1 + beta * U / (ema_U + eps)
    w = torch.clamp(w, 1.0, w_max)

# 6. Residual forward
r1_local = R1(s, actions)
r2_local = R2(s, actions)

r1_mean = r1_local.mean(dim=1, keepdim=True)
r2_mean = r2_local.mean(dim=1, keepdim=True)

delta1_local = r1_local - r1_mean
delta2_local = r2_local - r2_mean

# replay action is placed at index 0
delta1 = delta1_local[:, 0]
delta2 = delta2_local[:, 0]

# 7. Observed TD residual

```

```

with torch.no_grad():
    td1 = y - Q1(s, a)
    td2 = y - Q2(s, a)

# 8. Residual loss
loss_fit = (
    w * (delta1 - td1).pow(2)
    + w * (delta2 - td2).pow(2)
).mean()

loss_small = (
    delta1_local.pow(2).mean()
    + delta2_local.pow(2).mean()
)

loss_residual = loss_fit + mu * loss_small

residual_optimizer.zero_grad()
loss_residual.backward()
residual_optimizer.step()

# 9. Actor uses repaired critic during handoff
# Q_use = Q + lambda(t) * Delta

```

29. 第一版建议的最小实现

为了避免一次加入过多模块，建议 v0.1 只实现：

$$Q^{\text{use}} = Q + \Delta$$

$$\Delta = R - \text{mean}_{a \sim q} R$$

$$L_R = w(U)(\Delta - \delta)^2 + \mu \Delta^2$$

$$U = \text{Var}_a(Q_1 - Q_2).$$

其他设计：

- 不训练 Reference Critic；
- 不增加独立 FQE；
- 不加入强制 twin-consistency loss；
- 不改变 Base Critic 的 TD target；
- 不改变 replay buffer；
- Residual 只在 handoff early stage 影响 Actor；

- MC / FQE 只用于 evaluation, 不参与 Lancet training。
-

30. 最终故事

Lancet 的完整逻辑可以压缩成：

Offline Critic

进入 Online handoff 后产生 Bellman residual：

$$\delta = TQ - Q.$$

普通 O2O 方法让 Base Critic 慢慢吸收完整：

$$\delta.$$

Lancet 增加一个小型 fast residual branch：

$$R(s, a),$$

并通过：

$$\Delta = R - E_a R$$

把 correction 投影到 action-relative function space。

因此理想情况下：

$$\Delta \approx P_{\text{action}} \delta.$$

同时利用：

$$U = \text{Var}_a(Q_1 - Q_2)$$

发现 action-relative disagreement 较大的状态，并提高这些状态上的 Residual adaptation 强度。
最终形成：

Base TD learning + fast action-relative residual correction

核心目标不是替代正常 O2O learning，而是：

用更少的 online interaction，更快修复真正影响 policy 的 Critic component。

31. 当前方法最需要实验回答的问题

Lancet 当前真正的科研问题不是 “这个公式能不能写出来”，而是以下三个：

1. **Residual branch** 是否真的比直接更新 **Base Critic** 更快吸收 **early-online correction**?
2. 把 **Residual** 限制为 **action-relative subspace**，是否比 **unrestricted Residual** 更有利于 **policy repair**?
3. $U(s)$ 是否能够有效定位真实 **action-dependent error** 较大的状态，并进一步提高 **early-online sample efficiency**?

如果这三个问题分别得到肯定结果，那么 Lancet 的方法闭环就成立：

Motivation → Projection principle → Residual implementation → Faster O2O repair.